

## Étape 1

**Échantillon PMC**  
400 k paragraphes



**Llama-3.1-70B**  
annoter



**Annotations**  
type, domaine, intérêt, langue

entraîner le classifieur



## Étape 2

**PMC complet**  
133 M paragraphes



**XLM-RoBERTa**  
classer



**Corpus annoté**  
133 M + annotations