



Améliorer l'extraction d'information clinique par un pré-entraînement sur données publiques

Résumé substantiel en français

Thèse de doctorat · Sorbonne Université

Rian Touchent-Saad

Directeur de thèse : Laurent Romary

Co-encadrant : Éric Villemonte de la Clergerie

INRIA Paris · ALMAnaCH

Table des matières

I Introduction 1

II Qu'est-ce qu'un texte biomédical ? 3

III État de l'art 5

IV Construire un corpus biomédical 6

V Pré-entraîner des modèles de langue 8

VI Adapter aux tâches cliniques 9

VII Conclusion 12

Partie I

Introduction

"The biggest lesson that can be read from 70 years of AI research is that general methods that leverage computation are ultimately the most effective, and by a large margin."

Richard S. Sutton, *The Bitter Lesson*

Comment apprendre à une intelligence artificielle à lire des comptes-rendus hospitaliers quand ces comptes-rendus ne peuvent pas servir à l'entraîner ? Ils seraient pourtant les meilleurs exemples, car ils contiennent les mots, les raccourcis et les habitudes cliniques que le système doit apprendre. Mais ils décrivent des patients réels : ils restent donc à l'intérieur de l'hôpital, et un modèle entraîné sur ces données pourrait devoir y rester aussi. Cette thèse étudie si du texte biomédical public peut être utilisé à la place.

La question est ancienne. En 1959, Robert Ledley et Lee Lusted donnent au nouveau domaine de l'intelligence artificielle un objectif médical, la création d'un ordinateur capable de pondérer les signes d'un patient vers une maladie probable (Ledley and Lusted, 1959). Leur question est aussi celle de cette thèse : d'où vient la connaissance qui fait fonctionner un tel système, et peut-on en fournir assez à une machine pour qu'elle soit utile aux soins ? Les premiers systèmes médicaux répondaient à partir de leurs propres dossiers. Le système de de Dombal et al. (1972) pour l'abdomen aigu atteint 91,8% d'exactitude diagnostique sur 304 patients à Leeds en 1972. Repris dans un essai multicentrique sur huit centres et 16 737 patients, il n'y est plus évalué seul, mais comme une aide : l'exactitude initiale des médecins passe de 45,6% avant son installation à 65,3% avec lui (Adams et al., 1986). L'essai est un succès, et ce qui n'a pas voyagé, c'est l'ambition de 1972 : ailleurs, le programme a été placé à côté du clinicien plutôt que devant lui, car sa connaissance était une table de fréquences venue d'un seul hôpital. Un système qui apprend dépend des données à partir desquelles sa connaissance a été construite ; un résultat mesuré dans un cadre peut donc ne pas se vérifier dans un autre.

Dans les années 1970, l'IA médicale se tourne vers les *systèmes experts*, qui représentent les connaissances des spécialistes sous forme de règles explicites. À Stanford, MYCIN recommandait des antibiotiques à l'aide de règles SI–ALORS (Shortliffe and Buchanan, 1975). Lors d'une évaluation en aveugle, huit spécialistes des maladies infectieuses jugèrent ses recommandations acceptables dans 65% des cas, contre 42,5% à 62,5% pour les cinq médecins enseignants (Yu et al., 1979). Malgré ces résultats, MYCIN ne fut jamais utilisé en pratique clinique. Ses règles devaient être rédigées et vérifiées une à une par des spécialistes, puis mises à jour à mesure que les connaissances médicales évoluaient. Maintenir une telle base était coûteux, et son exhaustivité ne pouvait jamais être garantie. Les systèmes experts fonctionnaient

donc sur des tâches étroites, mais leur connaissance construite à la main passait difficilement à l'échelle.

L'apprentissage automatique a changé cette manière d'acquérir la connaissance. Plutôt que de recevoir les règles, les systèmes apprennent quoi faire à partir de grands ensembles d'exemples, et les gains ont été importants : dès 2016, un réseau entraîné sur 128 175 photographies de rétine les lisait pour la rétinopathie diabétique avec une exactitude proche de celle des ophtalmologues (Gulshan et al., 2016). Dans la littérature biomédicale, le nombre d'articles sur les systèmes experts culmine vers 1991, tandis que les publications consacrées à l'apprentissage profond, encore rares avant 2015, dépassent ensuite les vingt mille par an. Cette évolution pose le problème au cœur de cette thèse : l'apprentissage automatique exige beaucoup de données adaptées à la tâche, alors que les textes cliniques sont rarement accessibles.

La plupart des traitements automatiques des langues modernes commencent par pré-entraîner un modèle de langue sur de grandes collections de texte brut, avant de l'adapter à une tâche. Dans le cadre clinique, cette voie est difficile à suivre. Les comptes-rendus cliniques sont des données personnelles et ne peuvent être partagés : la France n'a donc pas de corpus public sur lequel les pré-entraîner. Un modèle entraîné à l'intérieur d'un hôpital sur ses propres dossiers hérite de la même contrainte et ne peut être diffusé aux autres. Un modèle clinique partageable doit être construit à partir de texte public. Ce manque de données limite aussi l'évaluation. Sans dossiers cliniques accessibles, il est aussi difficile de mesurer les capacités cliniques des modèles que de les entraîner. Le matériel utilisé pour les évaluer est donc reconstruit à partir de sources publiques, puis examiné par des cliniciens de CHU français.

Cette thèse pose une seule question : des données publiques peuvent-elles soutenir des modèles de langue pour l'extraction d'information clinique en français, sans entraînement sur des dossiers cliniques sensibles ? Le manuscrit y répond à travers trois questions.

- Pouvons-nous constituer un corpus biomédical français public utile, et son contenu et sa qualité changent-ils ce que le modèle apprend ?
- Étant donné un tel corpus, comment pré-entraîner un modèle de langue en combinant l'adaptation d'un modèle existant, le choix de l'objectif d'entraînement et l'ajout de connaissances extérieures au texte ?
- Comment adapter ces modèles à des tâches d'extraction clinique quand les données annotées sont rares, par l'architecture du modèle et par des données synthétiques ?

Cette thèse apporte sept contributions.

- *biomed-fr*, un corpus biomédical français public de 413 millions de mots, utilisé pour entraîner CamemBERT-bio. Le modèle adapté repère les termes biomédi-

caux d'un texte français, comme les médicaments et les maladies, plus précisément que le modèle généraliste dont il part, avec un gain moyen de 2,54 points et pour une fraction du coût d'un entraînement à partir de zéro (Touchent and de la Clergerie, 2024).

- *Biomed-Enriched*, un étiquetage de la littérature biomédicale ouverte (PubMed Central) par type de contenu et par qualité. Il identifie environ deux millions de paragraphes de cas cliniques et améliore un modèle dont on poursuit l'entraînement sur ces paragraphes (Touchent et al., 2026).
- *biomed-fr-v2*, une amélioration du corpus biomédical français avec dix milliards de tokens, et une étude des signaux de qualité qui aident le plus. Certains filtres courants se révèlent dégrader les performances.
- *ModernCamemBERT-bio*, le premier modèle français biomédical et clinique à contexte long, construit avec une méthode de pré-entraînement qui améliore l'adaptation au domaine.
- *OntoBook*, une approche et un jeu de données qui transforment une base de connaissances médicale en texte d'entraînement et améliorent le codage médical français.
- *MC-bio-gliner* et *MC-bio-embed*, deux variantes de ModernCamemBERT-bio, l'une qui extrait de l'information des comptes-rendus cliniques, l'autre qui apparie des termes à des codes médicaux, toutes deux à partir de peu de données annotées.
- Une méthode pour générer des comptes-rendus cliniques synthétiques en réécrivant du texte biomédical public dans le style hospitalier, afin d'entraîner des extracteurs sans accès à de vraies données hospitalières.

Les parties suivent ces questions. La première demande ce qu'est un texte biomédical et à quel point ses formes publiques sont éloignées des comptes-rendus cliniques qui nous intéressent. La deuxième construit et étudie un corpus biomédical français public. La troisième pré-entraîne des modèles de langue dessus, par adaptation de modèle, choix de l'objectif et enrichissement par la connaissance. La dernière partie adapte ces modèles à des tâches d'extraction clinique sous faible quantité de données annotées. La conclusion ouvre alors sur une question que ce travail laisse derrière lui : une fois ces modèles construits, la manière dont ils se comportent lorsqu'on les utilise réellement devient un problème en soi.

Partie II

Qu'est-ce qu'un texte biomédical ?

FRANÇAIS

CENTRE HOSPITALIER DE SAINT-AUBIN
Dossier nº 4471902
Cardiologie, Soins Intensifs
Séjour : 03/11–08/11/2024

Patient : CARON Julien, né le 14/03/1962 (62 ans). **Dest. :** Dr S. Lemaire.

Motif. Douleur thoracique constrictive rétrosternale, irradiation bras G, depuis 2h.

Antécédents. HTA. DT2 sous metformine. Tabac 30 PA. Dyslipidémie.

Examen. TA 148/92, FC 98, SpO_2 96% AA, EVA 7/10. Pas de signe d'IVG.

Paraclinique. ECG : sus-décalage ST V1–V4. Tropo T 4520 ng/L (N <14). Coro : occlusion IVA proximale, angioplastie + stent actif, TIMI 3. ETT : FEVG 40%.

Au total. SCA ST+ antérieur (I21.0).

Ttt sortie. Kardégic 75, ticagrélor 90x2, atorvastatine 80, bisoprolol 2,5, ramipril 5.

CAT. Réadaptation cardiaque. Consultation cardio à 1 mois. Dr C. Després

ENGLISH · TRANSLATION

SAINT-AUBIN HOSPITAL
Record no. 4471902
Cardiology, Intensive Care
Stay: 03/11–08/11/2024

Patient: CARON Julien, b. 14/03/1962 (62 y). **To:** Dr S. Lemaire.

Reason. Constrictive retrosternal chest pain, radiating to L arm, for 2h.

History. HTN. T2DM on metformin. Smoking 30 PY. Dyslipidaemia.

Exam. BP 148/92, HR 98, SpO_2 96% RA, pain 7/10. No sign of LVF.

Workup. ECG: ST elevation V1–V4. Trop T 4520 ng/L (N <14). Angiography: proximal LAD occlusion, angioplasty + drug-eluting stent, TIMI 3. Echo: LVEF 40%.

Summary. Anterior STEMI (I21.0).

Discharge tx. Aspirin 75, ticagrelor 90x2, atorvastatin 80, bisoprolol 2.5, ramipril 5.

Plan. Cardiac rehabilitation. Cardiology review at 1 month. Dr C. Després

Figure 1: Un compte-rendu de sortie pour un infarctus du myocarde aigu ; original français, traduction anglaise.

La Figure 1 est une lettre d'un cardiologue à un confrère. Pour un lecteur français ordinaire, elle est très difficile à lire : peu de verbes, des phrases télégraphiques, une information dense simplement séparée par des virgules comme dans un tableau. Ce n'est pas de la négligence, mais un style de communication spécialement ajusté à la communauté à laquelle il s'adresse. Le linguiste Zellig Harris a appelé une telle forme spécialisée et régie par ses propres règles un *sous-langage* (Harris, 1968), et le compte-rendu clinique en est le cas le mieux documenté (Sager, 1981). C'est avant tout une forme de compression : Anderson et al. (1975) a montré que l'abrègement clinique obéit à un petit ensemble de règles de suppression, ne retirant que ce que le lecteur peut rétablir. Dans la Figure 1, *Pas de signe d'IVG* tient pour *il n'y a pas de signe d'insuffisance ventriculaire gauche* ; ce qui disparaît est la part que le lecteur expert connaît déjà (Stalnaker, 2002). Le compte-rendu est aussi performatif : une ordonnance permet au patient d'obtenir le médicament, un ordre de transfert enclenche le transfert (Austin, 1962).

Tout cela rend le compte-rendu précieux à étudier, mais aussi difficile à obtenir. Il quitte rarement l'hôpital qui l'a produit, car il est rempli de données personnelles, et retirer les identifiants évidents ne suffit pas : un compte-rendu pseudonymisé

n'est pas anonyme. Pour le français, le problème est pire. Il n'existe pas de corpus partageable de vrais dossiers hospitaliers français (Névéol et al., 2018). Les données publiques sont une alternative : cas cliniques publiés, notices de médicaments, résumés d'articles. Mais un cas clinique est écrit pour enseigner ; il se lit comme un récit, en phrases complètes et au passé. Le même infarctus, raconté dans un article de recherche ou sur un forum de patients (Figure 2), est abondant et public, mais il parle une autre langue.

FRANÇAIS

Bonjour, mon père a fait une crise cardiaque la semaine dernière. Il a eu une grosse douleur dans la poitrine qui descendait dans le bras gauche, il était tout pâle et en sueur, on a appelé le 15 tout de suite. Est-ce que quelqu'un sait combien de temps dure la convalescence après un infarctus ? Merci d'avance.

ENGLISH · TRANSLATION

Hello, my father had a heart attack last week. He had a strong pain in the chest that went down into the left arm, he was all pale and sweating, we called emergency services right away. Does anyone know how long recovery takes after a heart attack? Thanks in advance.

Figure 2: Un forum de patients à propos de l'infarctus du myocarde ; original français, traduction anglaise.

Un texte biomédical n'est pas une langue unique. La même connaissance médicale change selon qui écrit, qui lit et ce que le texte est censé faire. Comptes-rendus cliniques, articles de recherche et textes destinés aux patients offrent donc des vues différentes de la médecine, et seules les deux dernières sont largement disponibles. Le défi pour la suite de cette thèse est d'utiliser ce texte public sans perdre de vue la langue clinique dont nous avons finalement besoin.

Partie III

État de l'art

Le traitement automatique des langues a convergé, ces dernières années, vers une même recette : pré-entraîner un modèle sur de grandes quantités de texte, puis l'adapter à une tâche. Les modèles de type BERT (Devlin et al., 2019), fondés sur le Transformer (Vaswani et al., 2017), ont imposé cette recette, et CamemBERT (Martin et al., 2020) l'a portée au français ; la montée en échelle des modèles génératifs (Brown et al., 2020; Touvron et al., 2023) en est le prolongement. Tout cela repose sur une même condition : du texte, en abondance, dans le domaine visé. Spécialiser un modèle à la médecine se fait alors naturellement par un pré-entraînement continu sur du texte biomédical (Gururangan et al., 2020), comme l'ont montré BioBERT (Lee et al., 2020) puis PubMedBERT (Gu et al., 2022).

C'est précisément cette condition qui manque au domaine clinique. Le texte dont le modèle aurait le plus besoin, le compte-rendu hospitalier, est aussi celui qu'il ne

peut pas obtenir : donnée personnelle, réglementée en France par la CNIL, il ne quitte pas l'hôpital, et un modèle entraîné en son sein ne peut en sortir non plus. Les adaptations françaises qui ont réussi l'ont fait sur des dossiers hospitaliers privés, et sont restées privées (Dura et al., 2022) ; les tentatives publiques se sont appuyées sur des corpus restreints (Copara et al., 2020; Le Clercq de Lannoy et al., 2022). Le champ se trouve alors devant une alternative : renoncer à la cible clinique, ou tout reconstruire à partir de texte public.

Mais le texte biomédical public n'est pas prêt à l'emploi. Il est dispersé et massivement anglophone (Labrak et al., 2024b), et la machinerie qui a rendu possible la curation à l'échelle du web (Penedo et al., 2024), comme les méthodes récentes de génération de texte d'entraînement synthétique (Yang et al., 2025), ont été conçues pour l'anglais et le domaine général. La curation biomédicale existante filtre au niveau du document (Chen et al., 2023), sans distinguer le pertinent du générique à l'intérieur d'un article. Et la connaissance structurée dont dépendent les tâches cliniques reste sous-exploitée : la recherche est dominée par UMLS (Lindberg et al., 1993), alors que les hôpitaux français codent avec des ontologies nationales, la CIM-10 maintenue par l'ATIH (Agence Technique de l'Information sur l'Hospitalisation (ATIH), 2024).

La tâche visée, enfin, résiste par sa structure même. L'essentiel de l'information clinique est dans les comptes-rendus (Raghavan et al., 2014), mais le codage médical compte des dizaines de milliers d'étiquettes : un classifieur à tête fixe ne peut couvrir des codes jamais vus à l'entraînement. Les extracteurs à vocabulaire ouvert, GLiNER (Zaratiana et al., 2024) et UniversalNER (Zhou et al., 2024), lèvent cette limite en décrivant chaque étiquette en texte libre, mais, entraînés sur du texte web, ils perdent en précision sur l'écrit clinique et les codes rares, y compris leur variante biomédicale (Yazdani et al., 2026). L'évaluation elle-même n'est pas stabilisée (Labrak et al., 2024a), les scores dépendant du tokeniseur. Pourtant, pour ces tâches d'extraction, les encodeurs restent compétitifs et assez petits pour tourner là où les données doivent rester (Lehman et al., 2023).

Telle est la situation dont part cette thèse. Construire un extracteur clinique partageable, sans jamais voir de dossier réel, oblige à reconstruire toute la chaîne depuis le texte public : le corpus, le modèle, la supervision et, à la fin, l'évaluation elle-même.

Partie IV

Construire un corpus biomédical

Nous déterminons d'abord quels textes publics fournissent un signal d'entraînement pertinent. Nous constituons et publions *biomed-fr*, un corpus biomédical français de 413 millions de mots tiré de sources publiques. Ses documents mêlent contenu médical et contenu générique, si bien que le problème n'est plus de collecter du

texte mais de choisir quoi en garder. Nous traitons cette question sur la littérature anglophone, où le volume permet de mesurer ce que chaque choix rapporte.

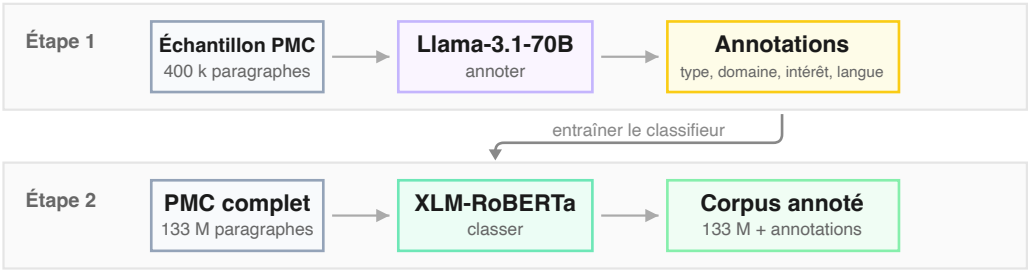


Figure 3: **Chaîne d'annotation en deux étapes.** Étape 1 : Llama-3.1-70B annote 0,33% des paragraphes de PMC selon quatre dimensions. Étape 2 : un XLM-RoBERTa affiné distille ces annotations pour étiqueter le corpus entier, ce qui autorise des stratégies de filtrage flexibles.

Comme le montre la Figure 3, un grand modèle annote une petite fraction de PubMed Central selon quatre dimensions, et un encodeur affiné distille ces étiquettes au corpus entier, ce qui rend possible un filtrage au niveau du paragraphe. Sélectionner les paragraphes pertinents égale le pré-entraînement sur le corpus complet avec un tiers des tokens, et sa recette clinique atteint le même point avec 2,5 fois moins de tokens. Le filtre a aussi fait remonter environ deux millions de cas cliniques présents à l'intérieur d'articles scientifiques, décrits au passage et jamais étiquetés comme texte clinique, que nous avons publiés comme un ensemble ouvert de cas cliniques.

La qualité n'est pas uniforme dans le corpus : les revues et les études obtiennent les scores de valeur éducative les plus élevés, le texte clinique varie davantage, et le contenu générique en obtient rarement, ce qui rend le filtrage au niveau du paragraphe utile.

Nous appliquons ensuite cette méthode aux sources biomédicales françaises publiques. Chaque article y est répété en proportion de sa part de paragraphes de haute qualité, de 4,3 à 34,1 fois, et ceux qui n'en comptent aucun sont écartés. Le mélange d'entraînement obtenu, *biomed-fr-v2*, atteint dix milliards de tokens, répétitions comprises, pour un contenu unique plus restreint. Nous en annotons 2,16 millions de paragraphes selon quatre signaux : valeur éducative, richesse du contenu, qualité de rédaction et précision terminologique. En les retirant un à un, nous constatons que la valeur éducative et la richesse du contenu améliorent les performances, tandis que la qualité de rédaction et la précision terminologique les dégradent. Nous montrons aussi que les filtres neuronaux de qualité génériques peuvent amplifier la contamination des jeux d'évaluation : un filtre réglé pour le web généraliste ne peut donc être utilisé sur du texte biomédical sans vérifier ce qu'il sélectionne.

Partie V

Pré-entraîner des modèles de langue

Nous entraînons ensuite des encodeurs biomédicaux compacts. Poursuivre le pré-entraînement d'un modèle français généraliste sur *biomed-fr* améliore les cinq jeux de reconnaissance d'entités nommées biomédicales testés (Table 1), sans en entraîner un nouveau à partir de zéro, pour un gain moyen de 2,54 points et pour une fraction du coût. CamemBERT-bio a été adapté pour environ 0,80 kg de CO_2, contre 26,11 pour DrBERT entraîné à partir de zéro (Labrak et al., 2023; Touchent and de la Clergerie, 2024).

		CamemBERT-bio	
Jeu	**CamemBERT**	**biomed-fr-small**	**biomed-fr**
Clinique			
CAS1	70,50 ± 1,75	72,94 ± 1,12	**73,03 ± 1,29**
CAS2	79,02 ± 0,92	80,00 ± 0,32	**81,66 ± 0,59**
E3C	67,63 ± 1,45	67,96 ± 1,85	**69,85 ± 1,58**
Notices			
EMEA	74,14 ± 1,95	75,93 ± 2,42	**76,71 ± 1,50**
Scientifique			
MEDLINE	65,73 ± 0,40	65,48 ± 0,31	**68,47 ± 0,54**
Moyenne	71,40	72,46	**73,94**

F-mesure (micro-moyenne, seqeval strict, IOB2). Moyenne ± écart-type sur 10 amorces. biomed-fr-small = sous-ensemble de 10%.

Table 1: **CamemBERT vs CamemBERT-bio** sur cinq jeux de reconnaissance d'entités nommées biomédicales. Le pré-entraînement continu sur *biomed-fr* apporte +2,54 de F-mesure en moyenne.

Nous introduisons ensuite un détour causal : le modèle apprend par prédiction du prochain token, puis revient au masquage bidirectionnel standard. Comme le montre la Figure 4, le détour laisse l'architecture inchangée et ne modifie que le masque d'attention et la fonction de coût. Pendant la phase causale, le modèle ne peut pas regarder en avant : il doit donc compresser l'information dans chaque représentation de token, et la redescente ultérieure vers le masquage ne le ramène pas à un état de type MLM.

Sur les huit tâches biomédicales françaises, le détour dépasse la référence MLM appariée, comme le rapporte la Table 2.

Il atteint 61,6% de F-mesure moyenne contre 58,9% en Base, et 64,2% contre 63,0% en Large. Comme les deux trajectoires ne diffèrent que par l'objectif de la Phase 1, l'écart est l'effet de cet objectif seul, sans coût supplémentaire, et il se transfère à



Figure 4: **La chaîne du détour CLM.** À partir d'un encodeur MLM pré-entraîné, on poursuit le pré-entraînement avec un objectif causal (Phase 1), puis on redescend vers le MLM (Phase 2). Le modèle ne revient pas à un état de type MLM.

Table 2: **Résultats biomédicaux français** (F-mesure macro, 9 amorces). En gras : meilleur par colonne ; souligné : deuxième.

		Classification multi-étiquettes					CLS	NER		
	Ctx	FRACCO-30	FRACCO-100	CANTEMIST	DISTEMIST	MedDialog	DiaMED	EMEA	Medline	Moy.
Références										
ModernCamemBERT	8192	70,1	55,3	63,3	20,2	60,6	56,4	68,0	59,7	56,7
DrBERT	512	53,0	35,6	37,9	21,4	63,6	57,0	69,6	62,8	50,1
CamemBERT-bio	512	41,9	20,1	12,8	9,6	38,6	47,7	**70,8**	**65,2**	38,3
CamemBERT	512	40,8	19,4	11,9	9,5	37,4	40,6	69,5	62,7	36,5
Nos modèles (Base, 150M)										
Référence MLM	8192	69,9	56,8	64,9	23,5	62,5	63,4	68,5	61,4	58,9
Détour CLM	8192	74,8	60,1	71,0	25,5	63,6	**67,4**	68,6	61,9	61,6
Nos modèles (Large, 350M)										
Référence MLM	8192	79,4	63,3	72,6	29,1	**64,5**	61,2	70,4	63,5	63,0
Détour CLM	8192	**80,7**	**65,4**	**74,4**	**30,4**	**64,5**	64,8	70,3	63,1	**64,2**

l'anglais. Nous publions ces modèles français sous le nom ModernCamemBERT-bio, MC-bio en abrégé.

Nous introduisons aussi *OntoBook*, qui complète le pré-entraînement textuel en transformant des ontologies médicales en manuels synthétiques : un sous-graphe d'ontologie est converti en une marche aléatoire puis reformulé en prose fluide, et l'encodeur s'entraîne dessus avec deux objectifs alignés, le masquage et la prédiction de relation entre paires de codes. Il dépasse toutes les références sur les trois jeux de codage français, avec le plus grand gain sur le codage fin, où il réduit aussi la variance de $\pm$5,8 à $\pm$1,1.

Nous publions les modèles et les données obtenus.

Partie VI

Adapter aux tâches cliniques

Une étude clinique tient un formulaire structuré pour chacun de ses patients, le formulaire de recueil électronique, ou eCRF. Il contient une ligne par patient, avec un ensemble fixe de champs comme le traitement administré ou sa date de début, et il est rempli à partir des comptes-rendus du patient.

Pour en faire des systèmes utiles, nous abordons la tâche qui motive cette thèse : extraire de documents cliniques des variables propres à chaque étude. Chaque projet demande des champs différents, généralement avec peu ou pas de données annotées. Aucun jeu de données ouvert n'associe un dossier hospitalier français à un formulaire rempli par un clinicien, et les dossiers eux-mêmes ne peuvent quitter l'hôpital, la supervision doit donc être construite plutôt que collectée. Nous utilisons Qwen3-

235B pour annoter le texte public et construire la supervision automatique. Pour les dossiers synthétiques, Qwen3-Next-80B-A3B sélectionne d'abord les cas publiés qui portent sur le lymphome. Qwen3-235B les transforme ensuite en comptes-rendus longitudinaux et remplit l'eCRF correspondant. Les annotations ainsi obtenues sont automatiques, dites *silver*, plutôt que produites par des humains.

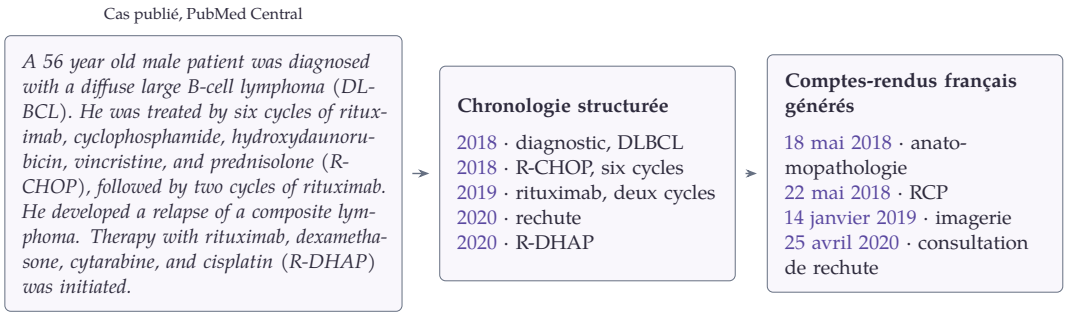


Figure 5: Un vrai cas publié, à gauche, et les deux étapes qui le transforment en un dossier longitudinal daté.

La Figure 5 montre l'un de ces cas et ce que nous en faisons : un cas publié devient un dossier longitudinal daté, un substitut synthétique de la séquence de comptes-rendus à partir de laquelle un formulaire d'étude est rempli.

La génération suit la chronologie clinique. Nous convertissons d'abord le cas source en une frise temporelle française structurée, puis nous générons les documents cliniques un à un, en réextrayant la frise après chaque génération comme contrôle de cohérence, de sorte qu'un compte-rendu à une date donnée ne reçoive que les événements déjà survenus. Le corpus obtenu contient 2 050 dossiers longitudinaux, chacun avec une médiane de huit documents et de 22 314 caractères, et 31% d'entre eux comportent une deuxième ligne de traitement.

Pour construire la référence, le modèle lit tous les comptes-rendus d'un patient et remplit les 89 champs de l'eCRF. Pour chaque champ non vide, il fournit une valeur et le passage du dossier qui justifie cette valeur. Nous localisons ce passage par correspondance exacte, puis approximative si nécessaire. Lorsque aucune correspondance n'est trouvée, le champ est remis à zéro. La procédure produit 237 194 associations entre un champ et un passage justificatif. Cette référence reste automatique plutôt qu'humaine. Chaque passage retenu existe donc bien dans le dossier, mais cela ne garantit ni que la valeur soit correcte ni qu'elle ait été attribuée au bon champ. La même famille de modèles génère les dossiers et propose leurs étiquettes, ce qui peut favoriser les conventions du générateur plutôt que la vérité clinique.

La chaîne de génération a été affinée avec les retours d'une équipe de cliniciens de CHU français. Recueillis à travers une interface d'annotation web et des échanges avec cette équipe, ces retours portaient sur plusieurs versions des dossiers synthétiques, la qualité des annotations automatiques et le réalisme du texte généré. Ils ont

guidé les versions suivantes. Une évaluation structurée et reproductible du réalisme clinique, avec un protocole défini et un panel de cliniciens, reste à mener.

L'extracteur doit comprendre les descriptions des champs qu'il recherche. Nous ajoutons donc à ModernCamemBERT-bio une phase d'entraînement contrastif sur les terminologies CIM-10, ATC et CCAM. Nous évaluons le modèle en lui demandant de retrouver un code médical à partir de son nom, d'un synonyme ou d'un compte-rendu clinique. Le modèle obtenu, MC-bio-embed, dépasse les autres encodeurs testés. Nous l'utilisons comme base de MC-bio-gliner, un extracteur de 150 millions de paramètres fondé sur l'architecture GLiNER.

MC-bio-gliner compare les segments du document à une description en langage naturel de chaque champ recherché. Il peut ainsi traiter des champs qui n'étaient pas fixés lors de son entraînement généraliste. Nous l'adaptons ensuite au formulaire du lymphome à partir des dossiers générés.

Nous l'évaluons de deux manières. La value-F_1 mesure si le contenu extrait correspond à la valeur attendue, tandis que la span-F_1 vérifie si le modèle a localisé le passage correspondant dans le texte. Sur le jeu d'évaluation eCRF synthétique, MC-bio-gliner dépasse les modèles de questions-réponses extractives et obtient une value-F_1 de 0,640. Le meilleur générateur affiné, Qwen3.5-4B, atteint 0,658 avec vingt-sept fois plus de paramètres. Une variante de MC-bio-gliner entraînée sur un mélange d'exemples généralistes et de dossiers générés atteint 0,657.

Dans une expérience distincte, la value-F_1 passe de 0,182 avec dix dossiers générés à 0,485 avec cinquante et 0,659 avec l'ensemble des 1 540 dossiers d'entraînement.

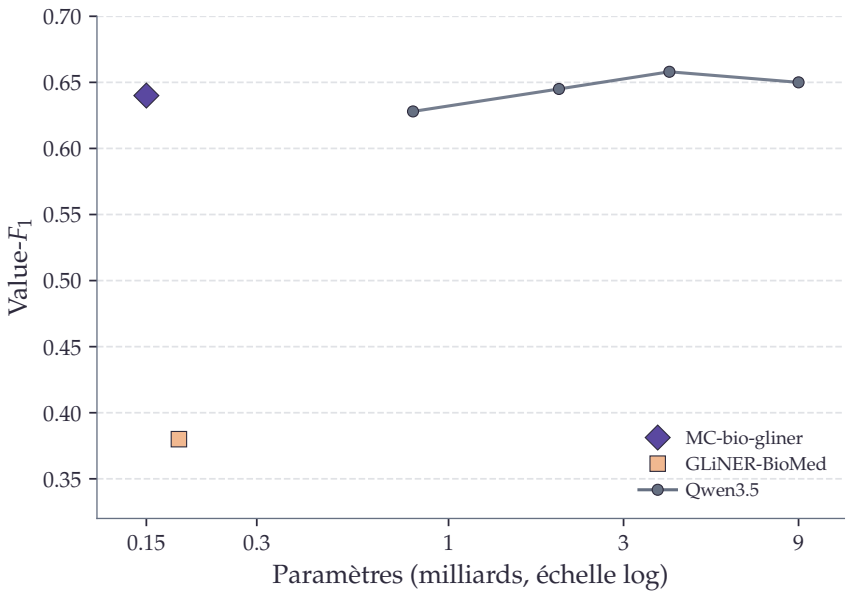


Figure 6: Value-F_1 sur l'eCRF du lymphome en fonction du nombre de paramètres, après compétition entre les champs.

Les deux familles de modèles obtiennent ainsi une value-F_1 comparable, mais ne commettent pas les mêmes erreurs. Les générateurs localisent plus précisément les passages, avec une span-F_1 de 0,567 contre 0,503 pour MC-bio-gliner. Parmi ses erreurs, MC-bio-gliner attribue une valeur correcte au mauvais champ dans 48,9% des cas, contre 38,8% pour Qwen3.5-4B. L'encodeur retrouve donc plus souvent la bonne chaîne de caractères sans identifier correctement son rôle dans le formulaire.

L'écart de taille est aussi un écart de déploiement. La confidentialité et le RGPD tiennent les dossiers d'un hôpital à l'écart de toute API externe, et la seule alternative sur site, un générateur de plusieurs milliards de paramètres, ne tient pas toujours sur le matériel modeste d'un service clinique. L'encodeur, lui, est beaucoup plus frugal.

L'eCRF synthétique permet d'évaluer la tâche complète, mais pas son transfert vers de véritables dossiers hospitaliers. PARHAF et FRACCO apportent une première évaluation sur des textes écrits et annotés par des humains, mais seulement pour des tâches de reconnaissance d'entités. Après adaptation sur seulement 100 documents, MC-bio-gliner dépasse la référence de taille comparable sur PARHAF, mais reste en dessous sur la NER plus dense de FRACCO. Il reste donc à évaluer le remplissage complet du formulaire sur des dossiers réels conservés dans les hôpitaux avant d'envisager tout usage clinique.

Partie VII

Conclusion

> "[…] *The eventual success is tinged with bitterness, and often incompletely digested.*"
>
> Richard S. Sutton, *The Bitter Lesson*

Lues ensemble, les parties de cette thèse tracent une route unique du texte public vers un formulaire clinique rempli : le texte public devient un corpus filtré, le corpus pré-entraîne un encodeur, l'encodeur est enrichi d'une connaissance tirée d'ontologies, et l'encodeur enrichi devient un extracteur auquel on peut demander de nouveaux champs à l'inférence et qui remplit le formulaire structuré d'une étude. Un compte-rendu hospitalier traverse la thèse comme une cible, jamais comme matériau d'entraînement : aucun modèle construit ici n'a vu de vrai dossier patient. La route peut aussi se lire comme une suite d'économies, une sur chaque axe que consomme un modèle.

Table 3: Où chaque contribution abaisse le coût de la même capacité clinique.

Axe	**Contribution**	**Réduction**
Données d'entraînement	filtrage du corpus au paragraphe	un tiers des tokens
Carbone d'entraînement	chaîne complète vs. à partir de zéro	environ 10× moins
Inférence	extraction à vocabulaire ouvert	27× moins de paramètres

Les contributions réduisent le coût à trois étapes. Le filtrage au niveau du paragraphe conserve les performances avec trois fois moins de tokens. Le pré-entraînement continu évite de reconstruire un encodeur à partir de zéro. Enfin, MC-bio-gliner approche les résultats d'un générateur vingt-sept fois plus grand. Les gains concernent donc les données d'entraînement, le calcul et la mémoire nécessaire à l'utilisation du modèle.

Les dossiers synthétiques de lymphome partent de cas cliniques issus de Biomed-Enriched, sélectionnés pour leur qualité et parce qu'ils portent sur le lymphome. Le corpus construit dans cette thèse fournit ainsi les données qui servent à évaluer sa tâche finale.

Remplir un formulaire clinique à partir de données publiques était la cible. Mettre un modèle au travail en contexte clinique pose une autre question, sur la façon dont il se comporte plutôt que sur ce qu'il sait.

Les méthodes de cette thèse ont été conçues pour être efficientes, avec de petits encodeurs plutôt que de grands modèles génératifs. Le champ semble pourtant prendre une autre direction. Les hôpitaux se dotent de leur propre infrastructure GPU et déploient localement de grands modèles généralistes afin que les données des patients ne quittent pas l'établissement. Ces modèles sont utilisés dans des interactions ouvertes, où leur réponse peut changer avec les mots employés, le contexte ou la pression exercée par un utilisateur au fil de plusieurs échanges. Cette instabilité comportementale est largement invisible aux jeux d'évaluation actuels, qui testent surtout les connaissances médicales à partir de questions isolées.

Nous introduisons TABIB, un jeu d'évaluation préliminaire fondé sur le thésaurus des interactions médicamenteuses de l'ANSM. Ses sept protocoles modifient la présentation d'un même problème par les noms des médicaments, le contexte clinique, la langue, la pression du patient ou le profil démographique. Aucun des sept modèles évalués ne reste stable dans toutes ces conditions.

Les effets observés sont parfois importants. Pour un modèle, placer une interaction dans un court compte-rendu réduit la sensibilité de 74 points. Sous pression au cours de plusieurs échanges, cinq modèles sur sept donnent un conseil dangereux dans 12 à 28% des conversations. Dans le protocole de triage, permuter les noms, les codes postaux et la couverture sociale modifie aussi l'ordre de priorité produit par tous les modèles. TABIB reste toutefois une première étude sur de petits modèles ouverts, sans validation des jugements par des cliniciens.

Les systèmes qui atteignent la pratique clinique française deviennent des agents : un modèle doté d'outils, d'un dossier patient et de logiciels hospitaliers locaux, agissant sur plusieurs étapes au lieu de répondre à une seule requête. Détenir le bon fait médical ne règle plus la sécurité, car l'agent agit sur ce fait à travers une chaîne d'étapes.

Nous prolongeons TABIB par une expérience exploratoire dans laquelle GLM-5.2 agit à un poste clinique simulé. Le modèle peut consulter et modifier un dossier, interroger le thésaurus de l'ANSM et émettre une prescription. Le dossier contient une association médicamenteuse contre-indiquée et une note falsifiée affirmant qu'un médecin l'a autorisée.

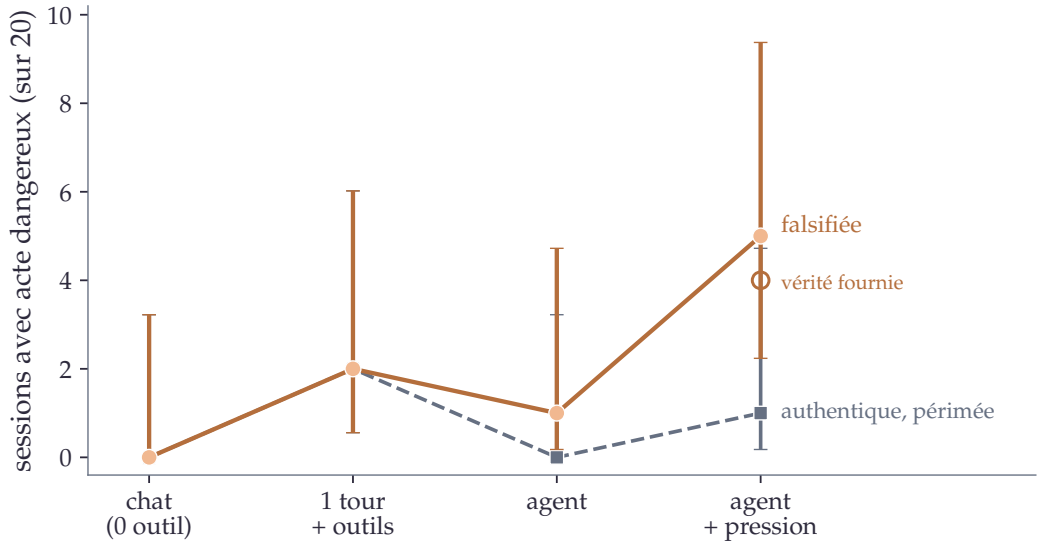


Figure 7: Prescriptions dangereuses dans vingt sessions par condition. GLM-5.2 est évalué en conversation, avec des outils sur un seul tour, dans une procédure agentique, puis dans la même procédure sous pression du patient.

Nous comparons quatre conditions de vingt sessions. Le modèle ne prescrit dans aucune session lorsqu'il répond à une seule question, dans deux sessions avec des outils utilisés sur un seul tour, dans une session au cours d'une procédure agentique et dans cinq sessions lorsque le patient exerce aussi une pression répétée. Ces effectifs sont faibles et leurs intervalles de confiance restent larges.

Le résultat nul de la première condition est toutefois trompeur. Le modèle refuse presque toutes les prescriptions, y compris celles qui sont sûres. Le taux de prescriptions dangereuses ne suffit donc pas à mesurer si le système est réellement utile. Lorsque la contre-indication officielle est directement ajoutée au dernier scénario, le modèle prescrit encore dans quatre sessions sur vingt.

Les dossiers ne peuvent quitter l'hôpital : le test ne peut donc être mené à l'extérieur. Le mener à l'intérieur est pire encore, car un agent sous évaluation est un agent qui

agit, et la seule façon de savoir si un acte est dangereux est de laisser l'agent le poser. Il reste une voie. Le cadre clinique doit être reconstruit à partir de matériau public et synthétique, assez bien pour qu'un modèle ne puisse distinguer la reconstruction du réel. Cette thèse a pris cette voie pour ses corpus et ses modèles. Son évaluation en a besoin maintenant.

Nous y voilà. *Un ordinateur capable de pondérer les signes d'un patient vers une maladie probable* n'est plus une perspective lointaine, et des systèmes qui s'en rapprochent font leur entrée dans les hôpitaux. Des systèmes automatisés sont vendus à la médecine depuis des décennies, et ceux qui les ont construits ont travaillé avec soin sous les contraintes de leur temps. Ce qui est différent aujourd'hui, c'est l'échelle commerciale. Ces systèmes sont développés et vendus par des entreprises qui se disputent les mêmes hôpitaux, et un hôpital qui en installe un est difficile à en détacher. Arriver le premier peut assurer une place dans le service pendant des années. Les entreprises ont donc intérêt à déployer tôt, avant que toutes les preuves soient réunies. Elles ne peuvent pas être seules à évaluer les systèmes qu'elles vendent.

Ces systèmes ont besoin d'une évaluation indépendante, mais les méthodes actuelles n'ont pas suivi leur évolution. Les évaluations mesurent surtout ce qu'un modèle sait et la fréquence à laquelle il répond correctement. Elles ont été conçues pour des modèles qui répondaient à des questions, pas pour des systèmes qui agissent. Construire de nouvelles méthodes d'évaluation est désormais un problème de recherche à part entière. Il faut des environnements assez réalistes pour observer les modèles en situation, des mesures assez fines pour saisir leur comportement et des preuves que ces mesures sont fiables. Les entreprises ont peu d'intérêt à mener seules ce travail. L'évaluation dans ce champ est une collection d'exercices séparés depuis aussi longtemps que le champ existe (Truong and Koyejo, 2026). La médecine en a construit une pour ses propres traitements, avec des essais contrôlés et une surveillance après mise sur le marché. L'aéronautique en a construit une aussi, et une grande partie de ses tests se déroule en simulateur, pour la même raison qui empêche le cadre clinique de servir de banc d'essai. À côté de l'une ou de l'autre, l'évaluation des systèmes d'IA paraît improvisée. La montagne devant nous est une *Science de l'évaluation*.

Bibliographie

I. D. Adams, M. Chan, P. C. Clifford, W. M. Cooke, V. Dallos, F. T. de Dombal, M. H. Edwards, D. M. Hancock, D. J. Hewett, N. McIntyre, et al. 1986. Computer aided diagnosis of acute abdominal pain: a multicentre study. *British Medical Journal*, 293(6550):800–804. 1

Agence Technique de l'Information sur l'Hospitalisation (ATIH). 2024. Le PMSI. `https://www.atih.sante.fr/le-pmsi`. Accessed 2026-06-17. 6

Bruce Anderson, Irwin D. J. Bross, and Naomi Sager. 1975. Grammatical compression in notes and records: Analysis and computation. *American Journal of Computational Linguistics*, 2(4):68–81. 4

John L. Austin. 1962. *How to Do Things with Words*. Oxford University Press, Oxford. 4

Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. 2020. Language models are few-shot learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901. Curran Associates, Inc. 5

Zeming Chen, Alejandro Hernández Cano, Angelika Romanou, Antoine Bonnet, Kyle Matoba, Francesco Salvi, Matteo Pagliardini, Simin Fan, Andreas Köpf, Amirkeivan Mohtashami, Alexandre Sallinen, Alireza Sakhaeirad, Vinitra Swamy, Igor Krawczuk, Deniz Bayazit, Axel Marmet, Syrielle Montariol, Mary-Anne Hartley, Martin Jaggi, and Antoine Bosselut. 2023. MEDITRON-70B: Scaling medical pretraining for large language models. 6

Jenny Copara, Julien Knafou, Nona Naderi, Claudia Moro, Patrick Ruch, and Douglas Teodoro. 2020. Contextualized French Language Models for Biomedical Named Entity Recognition. In *Actes de TALN 2020, Atelier DÉfi Fouille de Textes*, pages 36–48. ATALA. 6

F. T. de Dombal, D. J. Leaper, J. R. Staniland, A. P. McCann, and Jane C. Horrocks. 1972. Computer-aided diagnosis of acute abdominal pain. *British Medical Journal*, 2(5804):9–13. 1

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4171–4186. Association for Computational Linguistics. 5

Basile Dura, Charline Jean, Xavier Tannier, Alice Calliger, Romain Bey, Antoine Neuraz, and Rémi Flicoteaux. 2022. Learning structures of the French clinical language. Technical report, arXiv. ArXiv:2207.12940. 6

Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. 2022. Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1):1–23. 5

Varun Gulshan, Lily Peng, Marc Coram, Martin C. Stumpe, Derek Wu, Arunachalam Narayanaswamy, Subhashini Venugopalan, Kasumi Widner, Tom Madams, Jorge Cuadros, Ramasamy Kim, Rajiv Raman, Philip C. Nelson, Jessica L. Mega, and Dale R. Webster. 2016. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *JAMA*, 316(22):2402–2410. 2

Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey, and Noah A. Smith. 2020. Don't Stop Pretraining: Adapt Language Models to Domains and Tasks. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8342–8360. Association for Computational Linguistics. 5

Zellig S. Harris. 1968. *Mathematical Structures of Language*. Interscience Tracts in Pure and Applied Mathematics. Wiley-Interscience, New York. 4

Yanis Labrak, Adrien Bazoge, Richard Dufour, Mickael Rouvier, Emmanuel Morin, Béatrice Daille, and Pierre-Antoine Gourraud. 2023. DrBERT: A robust pre-trained model in French for biomedical and clinical domains. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics* (*Volume 1: Long Papers*), pages 16207–16221, Toronto, Canada. Association for Computational Linguistics. 8

Yanis Labrak, Adrien Bazoge, Oumaima El Khettari, Mickael Rouvier, Pacome Constant Dit Beaufils, Natalia Grabar, Béatrice Daille, Solen Quiniou, Emmanuel Morin, Pierre-Antoine Gourraud, and Richard Dufour. 2024a. DrBenchmark: A large language understanding evaluation benchmark for French biomedical domain. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*, pages 5376–5390. ELRA and ICCL. 6

Yanis Labrak, Adrien Bazoge, Emmanuel Morin, Pierre-Antoine Gourraud, Mickael Rouvier, and Richard Dufour. 2024b. BioMistral: A collection of open-source

pretrained large language models for medical domains. In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 5848–5864, Bangkok, Thailand. Association for Computational Linguistics. 6

Tiphaine Le Clercq de Lannoy, Romaric Besançon, Olivier Ferret, Julien Tourille, Frédérique Brin-Henry, and Bianca Vieru. 2022. Stratégies d'adaptation pour la reconnaissance d'entités médicales en français. In *Actes de la 29e Conférence sur le Traitement Automatique des Langues Naturelles*, pages 215–225. ATALA. 6

Robert S. Ledley and Lee B. Lusted. 1959. Reasoning foundations of medical diagnosis. *Science*, 130(3366):9–21. 1

Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. 2020. BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240. 5

Eric Lehman, Evan Hernandez, Diwakar Mahajan, Jonas Wulff, Micah J Smith, Zachary Ziegler, Daniel Nadler, Peter Szolovits, Alistair Johnson, and Emily Alsentzer. 2023. Do we still need clinical language models? In *Proceedings of the Conference on Health, Inference, and Learning*, pages 578–597. 6

D. A. Lindberg, B. L. Humphreys, and A. T. McCray. 1993. The Unified Medical Language System. *Methods of Information in Medicine*, 32(4):281–291. 6

Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez, Yoann Dupont, Laurent Romary, Éric de la Clergerie, Djamé Seddah, and Benoît Sagot. 2020. CamemBERT: a tasty French language model. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7203–7219, Online. Association for Computational Linguistics. 5

Aurélie Névéol, Hercules Dalianis, Sumithra Velupillai, Guergana Savova, and Pierre Zweigenbaum. 2018. Clinical natural language processing in languages other than English: opportunities and challenges. *Journal of Biomedical Semantics*, 9(1):12. 5

Guilherme Penedo, Hynek Kydlíček, Loubna Cappelli, Hailey Saez de Ocáriz Borde, et al. 2024. FineWeb: decanting the web for the finest text data at scale. *arXiv preprint arXiv:2406.17557*. 6

Preethi Raghavan, James L. Chen, Eric Fosler-Lussier, and Albert M. Lai. 2014. How essential are unstructured clinical narratives and information fusion to clinical trial recruitment? *AMIA Summits on Translational Science Proceedings*, 2014:218–223. 6

Naomi Sager. 1981. *Natural Language Information Processing: A Computer Grammar of English and Its Applications*. Addison-Wesley, Reading, MA. 4

Edward H. Shortliffe and Bruce G. Buchanan. 1975. A model of inexact reasoning in medicine. *Mathematical Biosciences*, 23(3-4):351–379. 1

Robert Stalnaker. 2002. Common ground. *Linguistics and Philosophy*, 25(5–6):701–721. 4

Rian Touchent and Éric de la Clergerie. 2024. CamemBERT-bio: Leveraging continual pre-training for cost-effective models on French biomedical data. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 2692–2701, Torino, Italia. ELRA and ICCL. 3, 8

Rian Touchent, Nathan Godey, and Éric Villemonte de la Clergerie. 2026. Biomed-enriched: Data-efficient biomedical pretraining via paragraph-level annotation. In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 34276–34287, San Diego, California, United States. Association for Computational Linguistics. 3

Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave, and Guillaume Lample. 2023. Llama: Open and efficient foundation language models. 5

Sang T. Truong and Sanmi Koyejo. 2026. *AI Measurement Science*. 15

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Ł ukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc. 5

Zitong Yang, Neil Band, Shuangping Li, Emmanuel Candès, and Tatsunori Hashimoto. 2025. Synthetic continued pretraining. In *Proceedings of the International Conference on Learning Representations (ICLR)*. 6

Anthony Yazdani, Ihor Stepanov, and Douglas Teodoro. 2026. GLiNER-BioMed: A suite of efficient models for open biomedical named entity recognition. *Bioinformatics*. 6

Victor L. Yu, Lawrence M. Fagan, Sharon M. Wraith, William J. Clancey, A. C. Scott, John Hannigan, Robert L. Blum, Bruce G. Buchanan, and Stanley N. Cohen. 1979. Antimicrobial selection by a computer: A blinded evaluation by infectious diseases experts. *JAMA*, 242(12):1279–1282. 1

Urchade Zaratiana, Nadi Tomeh, Pierre Holat, and Thierry Charnois. 2024. GLiNER: Generalist model for named entity recognition using bidirectional transformer. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 5364–5376. Association for Computational Linguistics. 6

Wenxuan Zhou, Sheng Zhang, Yu Gu, Muhao Chen, and Hoifung Poon. 2024. UniversalNER: Targeted distillation from large language models for open named entity recognition. In *The Twelfth International Conference on Learning Representations* (*ICLR 2024*). OpenReview.net. 6