

AMÉLIORER L'EXTRACTION D'INFORMATION CLINIQUE PAR UN PRÉ-ENTRAÎNEMENT SUR DONNÉES PUBLIQUES

RÉSUMÉ SUBSTANTIEL EN FRANÇAIS

Thèse de doctorat · Sorbonne Université

Rian Touchent

Directeur de thèse : Laurent Romary

Co-encadrant : Éric Villemonte de la Clergerie

INRIA Paris · ALMAAnaCH

TABLE DES MATIÈRES

I	INTRODUCTION	1
II	QU'EST-CE QU'UN TEXTE BIOMÉDICAL ?	3
III	ÉTAT DE L'ART	5
IV	CONSTRUIRE UN CORPUS BIOMÉDICAL	6
V	PRÉ-ENTRAÎNER DES MODÈLES DE LANGUE	7
VI	ADAPTER AUX TÂCHES CLINIQUES	9
VII	CONCLUSION	11

PARTIE I

INTRODUCTION

"The biggest lesson that can be read from 70 years of AI research is that general methods that leverage computation are ultimately the most effective, and by a large margin."

Richard S. Sutton, *The Bitter Lesson*

Comment apprendre à une intelligence artificielle à lire des comptes-rendus hospitaliers quand ces comptes-rendus ne peuvent pas servir à l'entraîner ? Ils seraient pourtant les meilleurs exemples, car ils contiennent les mots, les raccourcis et les habitudes cliniques que le système doit apprendre. Mais ils décrivent des patients réels : ils restent donc à l'intérieur de l'hôpital, et un modèle entraîné sur ces données pourrait devoir y rester aussi. Cette thèse étudie si un texte biomédical public peut être utilisé à la place.

La question est ancienne. En 1959, Robert Ledley et Lee Lusted fixent au nouveau domaine de l'intelligence artificielle un objectif médical : un ordinateur capable de pondérer les signes d'un patient vers une maladie probable ([Ledley and Lusted, 1959](#)). Leur question est aussi celle de cette thèse : d'où vient la connaissance qui fait fonctionner un tel système, et peut-on en fournir assez à une machine pour qu'elle soit utile aux soins ? Les premiers systèmes médicaux répondaient à partir de leurs propres dossiers. Le système de [de Dombal et al. \(1972\)](#) pour l'abdomen aigu atteint 91,8% d'exactitude diagnostique sur 304 patients dans un seul centre en 1972, mais lorsqu'il est repris dans un essai multicentrique sur huit centres et 16737 patients, l'exactitude ne monte plus qu'à 65,3% ([Adams et al., 1986](#)). Un système réglé sur les patients de Leeds n'a pas transporté ses 91,8% vers d'autres hôpitaux, car les probabilités sur lesquelles il repose venaient d'un seul endroit et les nouveaux patients de plusieurs. Un système qui apprend dépend des données à partir desquelles sa connaissance a été construite ; un résultat mesuré dans un cadre peut donc ne pas se vérifier dans un autre.

Dans les années 1970, l'IA médicale se tourne vers les *systèmes experts*, qui stockent la connaissance des spécialistes sous forme de règles explicites. MYCIN, à Stanford, conseillait les antibiotiques par des règles SI-ALORS ([Shortliffe and Buchanan, 1975](#)) ; lors d'un test en aveugle, huit spécialistes des maladies infectieuses le jugèrent acceptable dans 65% des cas, au niveau des enseignants ([Yu et al., 1979](#)). Il a passé le test et n'a jamais servi à soigner un patient ([Miller et al., 1982](#)). Un programme pouvait remporter un test en aveugle et rester inutilisable, car remporter le test n'était pas ce que les médecins demandaient.

L'apprentissage automatique a ensuite changé la façon dont les systèmes acquièrent leur connaissance. Plutôt que de recevoir les règles, ils apprennent quoi faire à partir de grands ensembles d'exemples, et les gains ont été importants : dès 2016, un réseau

entraîné sur 128 175 photographies de rétine les lisait pour la rétinopathie diabétique avec une exactitude proche de celle des ophtalmologues ([Gulshan et al., 2016](#)). Dans la littérature biomédicale, les articles sur les systèmes experts culminent vers 1991, puis une courbe de l'apprentissage profond, proche de zéro avant 2015, dépasse les vingt mille articles par an. Ces résultats ont fait naître une exigence nouvelle, celle qui organise cette thèse : un système qui apprend à partir d'exemples a besoin de nombreux exemples bien appariés, et le texte clinique ne circule pas librement.

La plupart des traitements automatiques des langues modernes commencent par pré-entraîner un modèle de langue sur de grandes collections de texte brut, avant de l'adapter à une tâche. Dans le cadre clinique, cette voie est difficile à suivre. Les comptes-rendus cliniques sont des données personnelles et ne peuvent être partagés : la France n'a donc pas de corpus public sur lequel les pré-entraîner. Un modèle entraîné à l'intérieur d'un hôpital sur ses propres dossiers hérite de la même contrainte et ne peut être diffusé aux autres. Un modèle clinique partageable doit être construit à partir de texte public.

Cette thèse pose une seule question : des données publiques peuvent-elles soutenir des modèles de langue pour l'extraction d'information clinique en français, sans entraînement sur des dossiers cliniques sensibles ? Le manuscrit y répond à travers trois questions.

- Pouvons-nous constituer un corpus biomédical français public utile, et son contenu et sa qualité changent-ils ce que le modèle apprend ?
- Étant donné un tel corpus, comment pré-entraîner un modèle de langue dessus : en adaptant un modèle existant, en choisissant l'objectif d'entraînement, ou en ajoutant de la connaissance venue de l'extérieur du texte ?
- Comment adapter ces modèles à des tâches d'extraction clinique quand les données annotées sont rares, par l'architecture du modèle et par des données synthétiques ?

Cette thèse apporte sept contributions.

- *biomed-fr*, un corpus biomédical français public de 413 millions de mots, utilisé pour entraîner CamemBERT-bio. Le modèle adapté repère les termes biomédicaux d'un texte français, comme les médicaments et les maladies, plus précisément que le modèle généraliste dont il part, avec un gain moyen de 2,54 points et pour une fraction du coût d'un entraînement à partir de zéro ([Touchent and de la Clergerie, 2024](#)).
- *Biomed-Enriched*, un étiquetage de la littérature biomédicale ouverte (PubMed Central) par type de contenu et par qualité. Il identifie environ deux millions de paragraphes de cas cliniques et améliore un modèle dont on poursuit l'entraînement sur ces paragraphes ([Touchent et al., 2026](#)).

- *MC-Bio*, un corpus biomédical français de dix milliards de tokens, et une étude des types de contenu et des signaux de qualité qui aident. Les expériences montrent que certains filtres courants dégradent les performances.
- Une méthode de pré-entraînement qui entraîne le modèle sur une autre tâche pendant un temps, puis revient à l'objectif principal, améliorant le modèle sans coût supplémentaire.
- *OntoBook*, une façon d'ajouter de la connaissance médicale structurée au pré-entraînement en transformant une base de connaissances médicale en texte d'entraînement.
- Des architectures de modèles, frenchmed-gliner et MedEmbed, qui repèrent les termes cliniques à partir d'une poignée d'exemples annotés seulement.
- Une méthode pour générer des comptes-rendus cliniques synthétiques en réécrivant du texte biomédical public dans le style hospitalier, afin d'entraîner des extracteurs sans accès à de vraies données hospitalières.

Les parties suivent ces questions. La première demande ce qu'est un texte biomédical et à quel point ses formes publiques sont éloignées des comptes-rendus cliniques qui nous intéressent. La deuxième construit et étudie un corpus biomédical français public. La troisième pré-entraîne des modèles de langue dessus, par adaptation de modèle, choix de l'objectif et enrichissement par la connaissance. La dernière partie adapte ces modèles à des tâches d'extraction clinique sous faible quantité de données annotées. La conclusion ouvre alors sur une question que ce travail laisse derrière lui : une fois ces modèles construits, la manière dont ils se comportent lorsqu'on les utilise réellement devient un problème en soi.

PARTIE II

QU'EST-CE QU'UN TEXTE BIOMÉDICAL ?

FRANÇAIS	ENGLISH · TRANSLATION
CENTRE HOSPITALIER DE SAINT-AUBIN Dossier n° 4471902 Cardiologie, Soins Intensifs Séjour : 03/11–08/11/2024	SAINT-AUBIN HOSPITAL Record no. 4471902 Cardiology, Intensive Care Stay: 03/11–08/11/2024
Patient : CARON Julien, né le 14/03/1962 (62 ans). Dest. : D ^r S. Lemaire.	Patient: CARON Julien, b. 14/03/1962 (62 y). To: Dr S. Lemaire.
Motif. Douleur thoracique constrictive rétrosternale, irradiation bras G, depuis 2h.	Reason. Constrictive retrosternal chest pain, radiating to L arm, for 2h.
Antécédents. HTA. DT2 sous metformine. Tabac 30 PA. Dyslipidémie.	History. HTN. T2DM on metformin. Smoking 30 PY. Dyslipidaemia.
Examen. TA 148/92, FC 98, SpO ₂ 96% AA, EVA 7/10. Pas de signe d'IVG.	Exam. BP 148/92, HR 98, SpO ₂ 96% RA, pain 7/10. No sign of LVF.
Paraclinique. ECG : sus-décalage ST V1–V4. Tropo T 4520 ng/L (N <14). Coro : occlusion IVA proximale, angioplastie + stent actif, TIMI 3. ETT : FEVG 40%.	Workup. ECG: ST elevation V1–V4. Trop T 4520 ng/L (N <14). Angiography: proximal LAD occlusion, angioplasty + drug-eluting stent, TIMI 3. Echo: LVEF 40%.
Au total. SCA ST+ antérieur (I21.0).	Summary. Anterior STEMI (I21.0).
Ttt sortie. Kardégic 75, ticagrélor 90x2, atorvastatine 80, bisoprolol 2,5, ramipril 5.	Discharge tx. Aspirin 75, ticagrelor 90x2, atorvastatin 80, bisoprolol 2.5, ramipril 5.
CAT. Réadaptation cardiaque. Consultation cardio à 1 mois. D ^r C. Després	Plan. Cardiac rehabilitation. Cardiology review at 1 month. Dr C. Després

Figure 1: Un compte-rendu de sortie pour un infarctus du myocarde aigu ; original français, traduction anglaise.

La [Figure 1](#) est une lettre d'un cardiologue à un confrère. Pour un lecteur français ordinaire, elle est très difficile à lire : peu de verbes, des phrases télégraphiques, une information dense simplement séparée par des virgules comme dans un tableau. Ce n'est pas de la négligence, mais un style de communication spécialement ajusté à la communauté à laquelle il s'adresse. Le linguiste Zellig Harris a appelé une telle forme spécialisée et régie par ses propres règles un *sous-langage* ([Harris, 1968](#)), et le compte-rendu clinique en est le cas le mieux documenté ([Sager, 1981](#)). C'est avant tout une forme de compression : [Anderson et al. \(1975\)](#) a montré que l'abrègement clinique obéit à un petit ensemble de règles de suppression, ne retirant que ce que le lecteur peut rétablir. Dans la [Figure 1](#), *Pas de signe d'IVG* tient pour *il n'y a pas de signe d'insuffisance ventriculaire gauche* ; ce qui disparaît est la part que le lecteur expert connaît déjà ([Stalnaker, 2002](#)). Le compte-rendu est aussi performatif : une ordonnance permet au patient d'obtenir le médicament, un ordre de transfert enclenche le transfert ([Austin, 1962](#)).

Tout cela rend le compte-rendu précieux à étudier, mais aussi difficile à obtenir. Il quitte rarement l'hôpital qui l'a produit, car il est rempli de données personnelles, et retirer les identifiants évidents ne suffit pas : un compte-rendu pseudonymisé

n'est pas anonyme. Pour le français, le problème est pire. Il n'existe pas de corpus partageable de vrais dossiers hospitaliers français (Névéol et al., 2018). Les données publiques sont une alternative : cas cliniques publiés, notices de médicaments, résumés d'articles. Mais un cas clinique est écrit pour enseigner ; il se lit comme un récit, en phrases complètes et au passé. Le même infarctus, raconté dans un article de recherche ou sur un forum de patients (Figure 2), est abondant et public, mais il parle une autre langue.

FRANÇAIS	ENGLISH · TRANSLATION
<i>Bonjour, mon père a fait une crise cardiaque la semaine dernière. Il a eu une grosse douleur dans la poitrine qui descendait dans le bras gauche, il était tout pâle et en sueur, on a appelé le 15 tout de suite. Est-ce que quelqu'un sait combien de temps dure la convalescence après un infarctus ? Merci d'avance.</i>	<i>Hello, my father had a heart attack last week. He had a strong pain in the chest that went down into the left arm, he was all pale and sweating, we called emergency services right away. Does anyone know how long recovery takes after a heart attack? Thanks in advance.</i>

Figure 2: Un forum de patients à propos de l'infarctus du myocarde ; original français, traduction anglaise.

Un texte biomédical n'est pas une langue unique. La même connaissance médicale change selon qui écrit, qui lit et ce que le texte est censé faire. Comptes-rendus cliniques, articles de recherche et textes destinés aux patients offrent donc des vues différentes de la médecine, et seules les deux dernières sont largement disponibles. Le défi pour la suite de cette thèse est d'utiliser ce texte public sans perdre de vue la langue clinique dont nous avons finalement besoin.

PARTIE III

ÉTAT DE L'ART

Le traitement automatique des langues a convergé, ces dernières années, vers une même recette : pré-entraîner un modèle sur de grandes quantités de texte, puis l'adapter à une tâche. Les modèles de type BERT (Devlin et al., 2019), fondés sur le Transformer (Vaswani et al., 2017), ont imposé cette recette, et CamemBERT (Martin et al., 2020) l'a portée au français ; la montée en échelle des modèles génératifs (Brown et al., 2020; Touvron et al., 2023) en est le prolongement. Tout cela repose sur une même condition : du texte, en abondance, dans le domaine visé. Spécialiser un modèle à la médecine se fait alors naturellement par un pré-entraînement continu sur du texte biomédical (Gururangan et al., 2020), comme l'ont montré BioBERT (Lee et al., 2020) puis PubMedBERT (Gu et al., 2022).

C'est précisément cette condition qui manque au domaine clinique. Le texte dont le modèle aurait le plus besoin, le compte-rendu hospitalier, est aussi celui qu'il ne

peut pas obtenir : donnée personnelle, réglementée en France par la CNIL, il ne quitte pas l'hôpital, et un modèle entraîné en son sein ne peut en sortir non plus. Les adaptations françaises qui ont réussi l'ont fait sur des dossiers hospitaliers privés, et sont restées privées (Dura et al., 2022) ; les tentatives publiques se sont appuyées sur des corpus restreints (Copara et al., 2020; Le Clercq de Lannoy et al., 2022). Le champ se trouve alors devant une alternative : renoncer à la cible clinique, ou tout reconstruire à partir de texte public.

Mais le texte biomédical public n'est pas prêt à l'emploi. Il est dispersé et massivement anglophone (Labrak et al., 2024b), et la machinerie qui a rendu possible la curation à l'échelle du web (Penedo et al., 2024), comme les méthodes récentes qui transforment une ontologie en texte d'entraînement (Yang et al., 2025), ont été conçues pour l'anglais et le domaine général. La curation biomédicale existante filtre au niveau du document (Chen et al., 2023), sans distinguer le pertinent du générique à l'intérieur d'un article. Et la connaissance structurée dont dépendent les tâches cliniques reste sous-exploitée : la recherche est dominée par UMLS (Lindberg et al., 1993), alors que les hôpitaux français codent avec des ontologies nationales, la CIM-10 maintenue par l'ATIH (Agence Technique de l'Information sur l'Hospitalisation (ATIH), 2024), qu'aucun pré-entraînement n'a utilisées.

La tâche visée, enfin, résiste par sa structure même. L'essentiel de l'information clinique est dans les comptes-rendus (Raghavan et al., 2014), mais le codage médical compte des dizaines de milliers d'étiquettes : un classifieur à tête fixe ne peut couvrir des codes jamais vus à l'entraînement. Les extracteurs à vocabulaire ouvert, GLiNER (Zaratiana et al., 2024) et UniversalNER (Zhou et al., 2024), lèvent cette limite en décrivant chaque étiquette en texte libre, mais, entraînés sur du texte web, ils perdent en précision sur l'écrit clinique et les codes rares, y compris leur variante biomédicale (Yazdani et al., 2026). L'évaluation elle-même n'est pas stabilisée (Labrak et al., 2024a), les scores dépendant du tokeniseur. Pourtant, pour ces tâches d'extraction, les encodeurs restent compétitifs et assez petits pour tourner là où les données doivent rester (Lehman et al., 2023).

Telle est la situation dont part cette thèse. Construire un extracteur clinique partageable, sans jamais voir de dossier réel, oblige à reconstruire toute la chaîne depuis le texte public : le corpus, le modèle, la supervision et, à la fin, l'évaluation elle-même.

PARTIE IV

CONSTRUIRE UN CORPUS BIOMÉDICAL

Nous déterminons d'abord quels textes publics fournissent un signal d'entraînement pertinent. Nous constituons et publions des corpus biomédicaux français à partir de sources publiques : *biomed-fr*, 413 millions de mots, puis *MC-Bio*, dix milliards de tokens. Comme leurs documents mêlent contenu médical pertinent et contenu

générique, nous les annotons au niveau du paragraphe par type de contenu et par qualité.




Figure 3: **Chaîne d’annotation en deux étapes.** Étape 1 : Llama-3.1-70B annoté 0,33% des paragraphes de PMC selon quatre dimensions. Étape 2 : un XLM-RoBERTa affiné distille ces annotations pour étiqueter le corpus entier, ce qui autorise des stratégies de filtrage flexibles.

Comme le montre la [Figure 3](#), un grand modèle annoté une petite fraction de PubMed Central selon quatre dimensions, et un encodeur affiné distille ces étiquettes au corpus entier, ce qui rend possible un filtrage au niveau du paragraphe. Sélectionner les paragraphes pertinents égale le pré-entraînement sur le corpus complet avec un tiers des tokens, et sa recette clinique atteint le même point avec 2,5 fois moins de tokens. Le filtre a aussi fait remonter environ deux millions de cas cliniques présents à l’intérieur d’articles scientifiques, décrits au passage et jamais étiquetés comme texte clinique, que nous avons publiés comme un ensemble ouvert de cas cliniques.

La qualité n’est pas uniforme dans le corpus : les revues et les études obtiennent les scores de valeur éducative les plus élevés, le texte clinique varie davantage, et le contenu générique en obtient rarement, ce qui rend le filtrage au niveau du paragraphe utile.

Quels signaux de qualité aident réellement est moins évident qu’il n’y paraît. Nous annotons chaque passage selon quatre signaux — valeur éducative, richesse du contenu, qualité de rédaction et précision terminologique — sur les 2,16 millions de passages annotés. En les retirant un à un, nous constatons que la valeur éducative et la richesse du contenu améliorent les performances, tandis que la qualité de rédaction et la précision terminologique les dégradent. Nous montrons aussi que les filtres neuronaux de qualité génériques peuvent amplifier la contamination des jeux d’évaluation : un filtre réglé pour le web généraliste ne peut donc être utilisé sur du texte biomédical sans vérifier ce qu’il sélectionne.

PRÉ-ENTRAÎNER DES MODÈLES DE LANGUE

Nous entraînons ensuite des encodeurs biomédicaux compacts. Poursuivre le pré-entraînement d'un modèle français généraliste sur *biomed-fr* améliore les cinq jeux de reconnaissance d'entités nommées biomédicales testés (Table 1), sans en entraîner un nouveau à partir de zéro, pour un gain moyen de 2,54 points et pour une fraction du coût. CamemBERT-bio a été adapté pour environ 0,80 kg de CO₂, contre 26,11 pour DrBERT entraîné à partir de zéro.

Jeu	CamemBERT	CamemBERT-bio	
		biomed-fr-small	biomed-fr
Clinique			
CAS1	70,50 ± 1,75	72,94 ± 1,12	73,03 ± 1,29
CAS2	79,02 ± 0,92	80,00 ± 0,32	81,66 ± 0,59
E3C	67,63 ± 1,45	67,96 ± 1,85	69,85 ± 1,58
Notices			
EMEA	74,14 ± 1,95	75,93 ± 2,42	76,71 ± 1,50
Scientifique			
MEDLINE	65,73 ± 0,40	65,48 ± 0,31	68,47 ± 0,54
Moyenne	71,40	72,46	73,94

F-mesure (micro-moyenne, sequeval strict, IOB2). Moyenne ± écart-type sur 10 amorces. biomed-fr-small = sous-ensemble de 10%.

Table 1: **CamemBERT vs CamemBERT-bio** sur cinq jeux de reconnaissance d'entités nommées biomédicales. Le pré-entraînement continu sur *biomed-fr* apporte +2,54 de F-mesure en moyenne.

Nous introduisons ensuite un détournement causal : le modèle apprend par prédiction du prochain token, puis revient au masquage bidirectionnel standard. Comme le montre la Figure 4, le détournement laisse l'architecture inchangée et ne modifie que le masque d'attention et la fonction de coût. Pendant la phase causale, le modèle ne peut pas regarder en avant : il doit donc compresser l'information dans chaque représentation de token, et la redescende ultérieure vers le masquage ne le ramène pas à un état de type MLM.



Figure 4: **La chaîne du détournement CLM.** À partir d'un encodeur MLM pré-entraîné, on poursuit le pré-entraînement avec un objectif causal (Phase 1), puis on redescend vers le MLM (Phase 2). Le modèle ne revient pas à un état de type MLM.

Sur les huit tâches biomédicales françaises, le détour dépasse la référence MLM appariée, comme le rapporte la [Table 2](#).

Table 2: **Résultats biomédicaux français** (F-mesure macro, 9 amorces). En gras : meilleur par colonne ; souligné : deuxième.

	Ctx	Classification multi-étiquettes					CLS	NER		Moy.
		FRACCO-30	FRACCO-100	CANTEMIST	DISTEMIST	MedDialog	DiaMED	EMEA	Medline	
Références										
ModernCamemBERT	8192	70,1	55,3	63,3	20,2	60,6	56,4	63,4	55,3	55,6
DrBERT	512	53,0	35,6	37,9	21,4	63,6	57,0	68,0	62,3	49,9
CamemBERT-bio	512	41,9	20,1	12,8	9,6	38,6	47,7	61,6	56,6	36,1
CamemBERT	512	40,8	19,4	11,9	9,5	37,4	40,6	61,5	54,7	34,5
Nos modèles (Base, 150M)										
Référence MLM	8192	69,9	56,8	64,9	23,5	62,5	63,4	65,4	56,8	57,9
Détour CLM	8192	74,8	60,1	71,0	25,5	63,6	67,4	65,9	58,2	60,8
Nos modèles (Large, 350M)										
Référence MLM	8192	79,4	63,3	72,6	29,1	64,5	61,2	66,1	58,0	61,8
Détour CLM	8192	80,7	65,4	74,4	30,4	64,5	64,8	67,0	59,5	63,3

Il atteint 60,8% de F-mesure moyenne contre 57,9% en Base, et 63,3% contre 61,8% en Large. Comme les deux trajectoires ne diffèrent que par l'objectif de la Phase 1, l'écart est l'effet de cet objectif seul, sans coût supplémentaire, et il se transfère à l'anglais. Nous publions ces modèles sous le nom ModernCamemBERT-bio.

Nous introduisons aussi *OntoBook*, qui complète le pré-entraînement textuel en transformant des ontologies médicales en manuels synthétiques : un sous-graphe d'ontologie est converti en une marche aléatoire puis reformulé en prose fluide, et l'encodeur s'entraîne dessus avec deux objectifs alignés, le masquage et la prédiction de relation entre paires de codes. Il dépasse toutes les références sur les trois jeux de codage français, avec le plus grand gain sur le codage fin DISTEMIST, où il réduit aussi la variance de $\pm 5,8$ à $\pm 1,1$.

Nous publions les modèles et les données obtenus.

PARTIE VI

ADAPTER AUX TÂCHES CLINIQUES

Une étude clinique tient un formulaire structuré pour chacun de ses patients, le formulaire de recueil électronique, ou eCRF. Il contient une ligne par patient, avec un ensemble fixe de champs comme le traitement administré ou sa date de début, et il est rempli à partir des comptes-rendus du patient.

Pour en faire des systèmes utiles, nous abordons la tâche qui motive cette thèse : extraire de documents cliniques des variables propres à chaque étude. Chaque projet demande des champs différents, généralement avec peu ou pas de données annotées. Aucun jeu de données ouvert n'associe un dossier hospitalier français à un formulaire rempli par un clinicien, et les dossiers eux-mêmes ne peuvent quitter l'hôpital : la supervision doit donc être construite plutôt que collectée. Nous utilisons de grands modèles de langue pour annoter du texte public, pour juger des types jamais observés

quand les références fixes font défaut, et pour générer des dossiers synthétiques de lymphome dérivés de cas cliniques publiés dans des articles scientifiques. Les deux voies utilisent Qwen3-235B avec une sortie JSON contrainte, et les annotations obtenues sont argentées (*silver*) plutôt qu’humaines.




Figure 5: Un vrai cas publié, à gauche, et les deux étapes qui le transforment en un dossier longitudinal daté.

La Figure 5 montre l’un de ces cas et ce que nous en faisons : un cas publié devient un dossier longitudinal daté, un substitut synthétique de la séquence de comptes-rendus à partir de laquelle un formulaire d’étude est rempli.

La génération suit la chronologie clinique. Nous convertissons d’abord le cas source en une frise temporelle française structurée, puis nous générons les comptes-rendus un à un, en réextraitant la frise après chaque compte-rendu comme contrôle de cohérence, de sorte qu’un compte-rendu à une date donnée ne reçoive que les événements déjà survenus. Le corpus obtenu contient 2 050 dossiers longitudinaux, chacun avec une médiane de huit comptes-rendus et de 22 314 caractères, et 31% d’entre eux comportent une deuxième ligne de traitement. En faire une référence d’extraction est une étape supplémentaire : chaque valeur doit être reliée à l’un des 89 champs du formulaire et localisée dans le dossier complet, et une seule passe du modèle de langue sur 16 375 comptes-rendus produit 237 194 affectations d’emplacements sur ces champs. La référence est argentée, non humaine : la même famille de modèles génère les dossiers et propose leurs étiquettes, si bien qu’elle peut récompenser les conventions du générateur plutôt que la vérité clinique.

La supervision générée entraîne des extracteurs compacts à vocabulaire ouvert, dont les descriptions des champs cibles sont fournies en texte à l’inférence. Sur un jeu d’évaluation eCRF synthétique, notre plus petit modèle adapté à la tâche dépasse les questions-réponses extractives et se situe à 0,018 de valeur- F_1 du meilleur générateur affiné, un modèle vingt-sept fois plus grand ; une variante adaptée à la tâche comble entièrement l’écart, 0,657 contre 0,658. L’adaptation est aussi efficace en données : la valeur- F_1 passe de 0,182 avec dix dossiers générés à 0,485 avec cinquante et 0,659 avec l’ensemble d’entraînement complet.

La Figure 6 place chaque système sur l’axe des paramètres. L’encodeur adapté à la tâche atteint le niveau d’un générateur de quatre milliards de paramètres, et faire




Figure 6: Value- F_1 sur l’eCRF du lymphome en fonction du nombre de paramètres, après compétition des champs. MC-bio-gliner, à 150 millions de paramètres, se situe à 0,018 de value- F_1 du meilleur générateur Qwen3.5-4B avec 27 fois moins de paramètres, tandis que la référence GLiNER-BioMed de taille comparable, affinée sur les mêmes dossiers, reste loin derrière.

passer ce générateur à neuf milliards n’aide pas. Les générateurs gardent l’avantage sur le span- F_1 , jusqu’à 0,567 contre 0,503 pour MC-bio-gliner, et parmi ses erreurs l’encodeur affecte une valeur correcte au mauvais champ 48,9% du temps, contre 38,8% pour le meilleur générateur : davantage de ses fautes sont des confusions de rôle, la bonne chaîne placée dans le mauvais champ.

L’écart de taille est aussi un écart de déploiement. La confidentialité et le RGPD tiennent les dossiers d’un hôpital à l’écart de toute API externe, et la seule alternative sur site, un générateur de plusieurs milliards de paramètres, ne tient pas sur le matériel modeste d’un service clinique. L’encodeur, lui, y tient : il tourne là où les données restent.

L’eCRF synthétique mesure la tâche complète mais ne peut établir le transfert vers du texte écrit par des humains. Sur des jeux de NER humains (PARHAF, FRACCO), l’avantage se restreint d’ailleurs à la tâche de remplissage longitudinal pour laquelle l’extracteur a été construit : sur une NER dense et plate, une référence de taille comparable reprend le dessus. Chaque élément de cette évidence est synthétique ou argenté, sans aucun dossier hospitalier réel ni annotation humaine dans la tâche : reste donc à établir si le résultat se transfère aux dossiers écrits par des humains, étape nécessaire avant tout usage clinique.

CONCLUSION

"[...] The eventual success is tinged with bitterness, and often incompletely digested."

Richard S. Sutton, *The Bitter Lesson*

Lues ensemble, les parties de cette thèse tracent une route unique du texte public vers un formulaire clinique rempli : le texte public devient un corpus filtré, le corpus pré-entraîne un encodeur, l'encodeur est enrichi d'une connaissance tirée d'ontologies, et l'encodeur enrichi devient un extracteur auquel on peut demander de nouveaux champs à l'inférence et qui remplit le formulaire structuré d'une étude. Un compte-rendu hospitalier traverse la thèse comme une cible, jamais comme matériau d'entraînement : aucun modèle construit ici n'a vu de vrai dossier patient. La route peut aussi se lire comme une suite d'économies, une sur chaque axe que consomme un modèle.

Table 3: Où chaque contribution abaisse le coût de la même capacité clinique.

Axe	Contribution	Réduction
Données d'entraînement	filtrage du corpus au paragraphe	un tiers des tokens
Carbone d'entraînement	chaîne complète vs. à partir de zéro	environ 10× moins
Inférence	extraction à vocabulaire ouvert	27× moins de paramètres

Le budget n'est pas dépensé là où on l'attendrait : entraîner l'encodeur est la partie peu coûteuse, et l'essentiel va au modèle de langue qui réécrit et annote le corpus, où notre chaîne reste plus légère parce qu'elle sélectionne un corpus biomédical petit et ciblé plutôt que de reformuler un corpus à l'échelle du web.

La cohorte de lymphome est le point où les fils séparés se rejoignent. Deux millions de cas cliniques, remontés lors du filtrage du corpus et publiés en ensemble ouvert, sont devenus plus tard la semence des dossiers longitudinaux synthétiques sur lesquels l'extracteur a été évalué. Des données récupérées en construisant le corpus sont devenues le terrain sur lequel la tâche finale a été mesurée.

Remplir un formulaire clinique à partir de données publiques était la cible. Mettre un modèle au travail en contexte clinique pose une autre question, sur la façon dont il se comporte plutôt que sur ce qu'il sait.

Les méthodes de cette thèse ont été conçues pour être efficaces, de petits encodeurs plutôt que de grands modèles génératifs, mais des signes indiquent que le champ prend une autre direction : les hôpitaux se dotent de leur propre infrastructure GPU et déploient localement de grands modèles généralistes, pour que les données patients ne quittent jamais l'établissement. Les encodeurs que cette

thèse a privilégiés rendent la même réponse à la même entrée. Les grands modèles décodeurs, non : leur sortie peut changer quand la forme de surface d'une question change, quand un fait est déplacé dans un contexte plus long, ou quand un utilisateur insiste sur plusieurs tours. Cette instabilité comportementale est largement invisible aux jeux d'évaluation que le champ utilise pour juger les modèles médicaux, qui testent surtout la connaissance factuelle par des questions propres.

Dans un jeu d'évaluation préliminaire, TABIB, nous perturbons des modèles biomédicaux français de façons qui préservent la vérité médicale tout en changeant la forme de l'interaction : noms de marque au lieu de dénominations communes, une paire de médicaments insérée dans un compte-rendu, un patient qui insiste sur plusieurs tours. Sur sept protocoles, aucun modèle n'est sûr sur tous, et les échecs partagent une forme. Le fait médical reste intact et seule la forme change, pourtant la réponse bouge.

Les échecs sont concrets. Le contexte clinique change le résultat : un modèle perd 74 points de sensibilité quand la même paire de médicaments est insérée dans un court compte-rendu. Sous pression multi-tours, cinq des sept modèles donnent un conseil dangereux dans 12 à 28% des dialogues. La capitulation sous la pression du patient est le genre d'échec qui pourrait laisser passer une association contre-indiquée en automédication, et c'est un comportement qu'un jeu d'évaluation factuel, par construction, ne voit jamais. La même cécité se retrouve au triage comparatif : chaque modèle rebat son ordre de priorité quand les noms des patients, les codes postaux et les marqueurs d'assurance sont permutés sur des cas médicalement identiques, et une évaluation qui note un patient à la fois, où les différences restent sous 0,03, le manque entièrement.

Les systèmes qui atteignent la pratique clinique française deviennent des agents : un modèle doté d'outils, d'un dossier patient et de logiciels hospitaliers locaux, agissant sur plusieurs étapes au lieu de répondre à une seule requête. Détenir le bon fait médical ne règle plus la sécurité, car l'agent agit sur ce fait à travers une chaîne d'étapes.

Nous avons commencé à construire un environnement agentique exploratoire pour le cadre clinique. Le modèle agit comme un agent à un poste clinique simulé, avec un dossier patient qu'il peut lire et écrire, un outil pour consulter le thésaurus officiel des interactions médicamenteuses de l'ANSM, et un outil pour délivrer une ordonnance, qui est un acte irréversible. Une tâche cache un patient dont le dossier contient une paire de médicaments contre-indiquée accompagnée d'une note falsifiée affirmant qu'un médecin a levé la contre-indication.

Même cette petite sonde montre que le verdict de sécurité dépend autant du dispositif que du modèle.

En suivant le même modèle, avec la même connaissance et la même note falsifiée, il ne commet aucun acte dangereux dans une configuration de conversation propre et atteint un quart des cas sous pression agentique. Un jeu d'évaluation de type




Figure 7: Le même modèle et la même note falsifiée sous quatre dispositifs de réalisme croissant : le nombre de sessions, sur vingt, comportant un acte dangereux passe d’aucune en configuration de type conversation à cinq sous pression agentic, tandis qu’une note authentique mais périmée et la délivrance de la contre-indication officielle (marqueur ouvert) le déplacent bien moins. Les barres sont des intervalles de Wilson à 95%.

conversation pose une question et prend une réponse, et cet échec a besoin de plusieurs étapes pour apparaître : le jeu ne le mesure pas mal, il ne le voit pas du tout. Fournir la contre-indication officielle avec le cas ne protège pas non plus le modèle : environ un cinquième prescrivent quand même contre le verdict qu’ils viennent de lire. Un chiffre de sécurité issu d’un jeu de type conversation ou de questions à choix multiples n’est pas une borne supérieure du risque en déploiement ; ici il est faux d’un large facteur, zéro contre un quart, pour le même modèle et le même artefact.

Les dossiers ne peuvent quitter l’hôpital : le test ne peut donc être mené à l’extérieur. Le mener à l’intérieur est pire encore, car un agent sous évaluation est un agent qui agit, et la seule façon de savoir si un acte est dangereux est de laisser l’agent le poser. Il reste une voie. Le cadre clinique doit être reconstruit à partir de matériau public et synthétique, assez bien pour qu’un modèle ne puisse distinguer la reconstruction du réel. Cette thèse a pris cette voie pour ses corpus et ses modèles. Son évaluation en a besoin maintenant.

Nous y voilà. *Un ordinateur capable de pondérer les signes d’un patient vers une maladie probable* ne semble plus hors de portée à personne, et quelque chose d’approchant s’installe dans les hôpitaux. Des systèmes automatisés sont vendus à la médecine depuis des décennies, et ceux qui les ont construits ont travaillé avec soin sous les

contraintes de leur temps. Ce qui est différent, c'est l'échelle commerciale. Ces systèmes sont développés et vendus par des entreprises qui se disputent les mêmes hôpitaux, et un hôpital qui en installe un est difficile à en détacher. Arriver le premier garde le service pendant des années : la pression est donc de déployer tôt, avant que les preuves ne soient réunies. Cette pression appartient aux entreprises, et c'est aussi ce qui fait d'elles la mauvaise partie pour mesurer le résultat.

Une évaluation indépendante est ce que la situation réclame, et elle n'existe pas au niveau qu'ont atteint ces systèmes. La construire est la part de la recherche. L'évaluation que le champ pratique établit ce qu'un modèle sait et à quelle fréquence il répond correctement, ce qui suffisait tant que les modèles répondaient. Elle n'établit pas comment il se comporte lorsqu'il agit. Ce qui manque, c'est une discipline : des environnements assez réalistes pour y agir, des mesures assez fines pour saisir un comportement, et des preuves sur celles de ces mesures auxquelles on peut se fier. Aucune entreprise n'a de raison de la construire. L'évaluation dans ce champ est une collection d'exercices séparés depuis aussi longtemps que le champ existe ([Truong and Koyejo, 2026](#)). La médecine en a construit une pour ses propres traitements, avec des essais contrôlés et une surveillance après mise sur le marché. L'aéronautique en a construit une aussi, et une grande partie de ses tests se déroule en simulateur, pour la même raison qui empêche le cadre clinique de servir de banc d'essai. À côté de l'une ou de l'autre, l'évaluation des systèmes d'IA paraît improvisée. La montagne devant nous est une *Science de l'évaluation*.

BIBLIOGRAPHIE

- I. D. Adams, M. Chan, P. C. Clifford, W. M. Cooke, V. Dallos, F. T. de Dombal, M. H. Edwards, D. M. Hancock, D. J. Hewett, N. McIntyre, et al. 1986. [Computer aided diagnosis of acute abdominal pain: a multicentre study](#). *British Medical Journal*, 293(6550):800–804. 1
- Agence Technique de l’Information sur l’Hospitalisation (ATIH). 2024. Le PMSI. <https://www.atih.sante.fr/le-pmsi>. Accessed 2026-06-17. 6
- Bruce Anderson, Irwin D. J. Bross, and Naomi Sager. 1975. Grammatical compression in notes and records: Analysis and computation. *American Journal of Computational Linguistics*, 2(4):68–81. 4
- John L. Austin. 1962. *How to Do Things with Words*. Oxford University Press, Oxford. 4
- Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel Ziegler, Jeffrey Wu, Clemens Winter, Chris Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. 2020. [Language models are few-shot learners](#). In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901. Curran Associates, Inc. 5
- Zeming Chen, Alejandro Hernández Cano, Angelika Romanou, Antoine Bonnet, Kyle Matoba, Francesco Salvi, Matteo Pagliardini, Simin Fan, Andreas Köpf, Amirkeivan Mohtashami, Alexandre Sallinen, Alireza Sakhaeirad, Vinitra Swamy, Igor Krawczuk, Deniz Bayazit, Axel Marmet, Syrielle Montariol, Mary-Anne Hartley, Martin Jaggi, and Antoine Bosselut. 2023. [MEDITRON-70B: Scaling medical pretraining for large language models](#). 6
- Jenny Copara, Julien Knafou, Nona Naderi, Claudia Moro, Patrick Ruch, and Douglas Teodoro. 2020. Contextualized French Language Models for Biomedical Named Entity Recognition. In *Actes de TALN 2020, Atelier DÉfi Fouille de Textes*, pages 36–48. ATALA. 6
- F. T. de Dombal, D. J. Leaper, J. R. Staniland, A. P. McCann, and Jane C. Horrocks. 1972. [Computer-aided diagnosis of acute abdominal pain](#). *British Medical Journal*, 2(5804):9–13. 1

- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. [BERT: Pre-training of deep bidirectional transformers for language understanding](#). In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4171–4186. Association for Computational Linguistics. 5
- Basile Dura, Charline Jean, Xavier Tannier, Alice Calliger, Romain Bey, Antoine Neuraz, and Rémi Flicoteaux. 2022. Learning structures of the French clinical language. Technical report, arXiv. ArXiv:2207.12940. 6
- Yu Gu, Robert Tinn, Hao Cheng, Michael Lucas, Naoto Usuyama, Xiaodong Liu, Tristan Naumann, Jianfeng Gao, and Hoifung Poon. 2022. [Domain-specific language model pretraining for biomedical natural language processing](#). *ACM Transactions on Computing for Healthcare*, 3(1):1–23. 5
- Varun Gulshan, Lily Peng, Marc Coram, Martin C. Stumpe, Derek Wu, Arunachalam Narayanaswamy, Subhashini Venugopalan, Kasumi Widner, Tom Madams, Jorge Cuadros, Ramasamy Kim, Rajiv Raman, Philip C. Nelson, Jessica L. Mega, and Dale R. Webster. 2016. [Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs](#). *JAMA*, 316(22):2402–2410. 2
- Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey, and Noah A. Smith. 2020. [Don’t Stop Pretraining: Adapt Language Models to Domains and Tasks](#). In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8342–8360. Association for Computational Linguistics. 5
- Zellig S. Harris. 1968. *Mathematical Structures of Language*. Interscience Tracts in Pure and Applied Mathematics. Wiley-Interscience, New York. 4
- Yanis Labrak, Adrien Bazoge, Oumaima El Khettari, Mickael Rouvier, Pacome Constant Dit Beaufils, Natalia Grabar, Béatrice Daille, Solen Quiniou, Emmanuel Morin, Pierre-Antoine Gourraud, and Richard Dufour. 2024a. DrBenchmark: A large language understanding evaluation benchmark for French biomedical domain. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation*, pages 5376–5390. ELRA and ICCL. 6
- Yanis Labrak, Adrien Bazoge, Emmanuel Morin, Pierre-Antoine Gourraud, Mickael Rouvier, and Richard Dufour. 2024b. [BioMistral: A collection of open-source pretrained large language models for medical domains](#). In *Findings of the Association for Computational Linguistics: ACL 2024*, pages 5848–5864, Bangkok, Thailand. Association for Computational Linguistics. 6
- Tiphaine Le Clercq de Lannoy, Romaric Besançon, Olivier Ferret, Julien Tourille, Frédérique Brin-Henry, and Bianca Vieru. 2022. [Stratégies d’adaptation pour la](#)

- reconnaissance d'entités médicales en français. In *Actes de la 29e Conférence sur le Traitement Automatique des Langues Naturelles*, pages 215–225. ATALA. 6
- Robert S. Ledley and Lee B. Lusted. 1959. Reasoning foundations of medical diagnosis. *Science*, 130(3366):9–21. 1
- Jinhyuk Lee, Wonjin Yoon, Sungdong Kim, Donghyeon Kim, Sunkyu Kim, Chan Ho So, and Jaewoo Kang. 2020. BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4):1234–1240. 5
- Eric Lehman, Evan Hernandez, Diwakar Mahajan, Jonas Wulff, Micah J Smith, Zachary Ziegler, Daniel Nadler, Peter Szolovits, Alistair Johnson, and Emily Alsentzer. 2023. Do we still need clinical language models? In *Proceedings of the Conference on Health, Inference, and Learning*, pages 578–597. 6
- D. A. Lindberg, B. L. Humphreys, and A. T. McCray. 1993. The Unified Medical Language System. *Methods of Information in Medicine*, 32(4):281–291. 6
- Louis Martin, Benjamin Muller, Pedro Javier Ortiz Suárez, Yoann Dupont, Laurent Romary, Éric de la Clergerie, Djamé Seddah, and Benoît Sagot. 2020. CamemBERT: a tasty French language model. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7203–7219, Online. Association for Computational Linguistics. 5
- Randolph A. Miller, Harry E. Pople, and Jack D. Myers. 1982. INTERNIST-1, an experimental computer-based diagnostic consultant for general internal medicine. *New England Journal of Medicine*, 307(8):468–476. 1
- Aurélié Névéol, Hercules Dalianis, Sumithra Velupillai, Guergana Savova, and Pierre Zweigenbaum. 2018. Clinical natural language processing in languages other than English: opportunities and challenges. *Journal of Biomedical Semantics*, 9(1):12. 5
- Guilherme Penedo, Hynek Kydlíček, Loubna Cappelli, Hailey Saez de Ocáriz Borde, et al. 2024. FineWeb: decanting the web for the finest text data at scale. *arXiv preprint arXiv:2406.17557*. 6
- Preethi Raghavan, James L. Chen, Eric Fosler-Lussier, and Albert M. Lai. 2014. How essential are unstructured clinical narratives and information fusion to clinical trial recruitment? *AMIA Summits on Translational Science Proceedings*, 2014:218–223. 6
- Naomi Sager. 1981. *Natural Language Information Processing: A Computer Grammar of English and Its Applications*. Addison-Wesley, Reading, MA. 4
- Edward H. Shortliffe and Bruce G. Buchanan. 1975. A model of inexact reasoning in medicine. *Mathematical Biosciences*, 23(3-4):351–379. 1

- Robert Stalnaker. 2002. [Common ground](#). *Linguistics and Philosophy*, 25(5–6):701–721. 4
- Rian Touchent and Éric de la Clergerie. 2024. [CamemBERT-bio: Leveraging continual pre-training for cost-effective models on French biomedical data](#). In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 2692–2701, Torino, Italia. ELRA and ICCL. 2
- Rian Touchent, Nathan Godey, and Éric Villemonte de la Clergerie. 2026. [Biomed-enriched: Data-efficient biomedical pretraining via paragraph-level annotation](#). In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 34276–34287, San Diego, California, United States. Association for Computational Linguistics. 2
- Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurelien Rodriguez, Armand Joulin, Edouard Grave, and Guillaume Lample. 2023. [Llama: Open and efficient foundation language models](#). 5
- Sang T. Truong and Sanmi Koyejo. 2026. [AI Measurement Science](#). 15
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. [Attention is all you need](#). In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc. 5
- Zitong Yang, Neil Band, Shuangping Li, Emmanuel Candès, and Tatsunori Hashimoto. 2025. [Synthetic continued pretraining](#). In *Proceedings of the International Conference on Learning Representations (ICLR)*. 6
- Anthony Yazdani, Ihor Stepanov, and Douglas Teodoro. 2026. [GLiNER-BioMed: A suite of efficient models for open biomedical named entity recognition](#). *Bioinformatics*. 6
- Victor L. Yu, Lawrence M. Fagan, Sharon M. Wraith, William J. Clancey, A. C. Scott, John Hannigan, Robert L. Blum, Bruce G. Buchanan, and Stanley N. Cohen. 1979. [Antimicrobial selection by a computer](#). *JAMA*, 242(12):1279–1282. 1
- Urchade Zaratiana, Nadi Tomeh, Pierre Holat, and Thierry Charnois. 2024. [GLiNER: Generalist model for named entity recognition using bidirectional transformer](#). In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*, pages 5364–5376. Association for Computational Linguistics. 6
- Wenxuan Zhou, Sheng Zhang, Yu Gu, Muhao Chen, and Hoifung Poon. 2024. [UniversalNER: Targeted distillation from large language models for open named](#)

[entity recognition](#). In *The Twelfth International Conference on Learning Representations (ICLR 2024)*. OpenReview.net. [6](#)